

COMPLETE_RESULTS

完整结果报告

1. 评测设置

本项目在可验证数学推理场景下评估 Hy3 的解题与过程推理能力。主实验从 MATH 数据集中选取45道无需图形输入的纯文本题目，覆盖 Level 1–5，其中各难度分别包含5、5、5、15、15题。

Solver分别在high和low reasoning_effort 下对同一45题生成完整可见过程和最终答案；两组使用相同题目、math-solver-v2、生成参数和答案校验协议，主要实验变量仅为推理强度。最终答案由独立答案验证器自动校验；low 条件下的45份可见解题过程进一步进行逐题人工复核，以获得过程正确性的人工参考标签。

本报告将未经错误注入、由Solver正常生成的输出称为常规模型解答；其中接受逐题人工复核的45份low解答构成常规解答验证集。另行人工构造的16例错误过程称为受控错误验证集。

no_think 未纳入过程评估主实验，因为该配置生成的显式推理过程较少，难以满足本项目对可见解题过程进行逐步评估的输入要求。

2. Solver总体结果

以下结果均针对常规模型解答计算，不包含受控错误验证集。

核心指标

指标	high	low
样本数	45	45
完整生成率	45/45（100%）	45/45（100%）
最终答案准确率	45/45（100%）	45/45（100%）
人工复核样本数	—	45
人工过程正确率	—	44/45（97.8%）
答案正确但过程错误	—	1/45（2.2%）

过程正确指可见解题过程中的关键推导能够成立，且不存在影响推理有效性的实质性计算、逻辑、条件遗漏或依据不足问题。最终答案准确率和过程正确率是两个独立指标；唯一过程错误样本虽然给出了正确答案，但可见推导中存在计算不一致。

现有high常规模型解答没有形成与low相同的45题统一人工过程标签，因此本报告不进行high/low过程正确率数值比较。

推理强度对照

指标	high	low	变化
Total tokens	311,089	113,594	−63.5%
Reasoning tokens	275,718	79,193	−71.3%

low相比high的total tokens减少63.5%，reasoning tokens减少71.3%；当前45题上没有观察到最终答案准确率下降。该对照用于描述Solver推理强度降低后的准确率—计算成本变化，只适

用于当前问题、单次生成实验，不代表Hy3总体性能。

3. 难度分层结果

MATH难度	样本数	high最终答案准确率	low最终答案准确率	low人工过程正确率
Level 1	5	5/5	5/5	5/5
Level 2	5	5/5	5/5	5/5
Level 3	5	5/5	5/5	5/5
Level 4	15	15/15	15/15	15/15
Level 5	15	15/15	15/15	14/15
合计	45	45/45	45/45	44/45

当前样本中，high和low在各Level均未出现最终答案错误；low人工过程在Level 1–4未观察到错误，Level 5出现1例过程错误。当前45道问题对照中，high与low条件下各难度层的最终答案准确率均保持100%，因此在最终答案指标上未观察到降低 reasoning_effort 带来的可见性能下降。由于high条件下未形成与low完全一致的人工过程标签，本报告不进一步比较两种推理强度下的过程质量差异。

当前样本未观察到明确的答案准确率下降区间，也不足以确定稳定的难度临界点。

4. 错误类型

常规解答验证集中仅观察到1例过程错误，类型为 calculation_error，因此该验证集不足以形成具有解释意义的错误类型分布。为覆盖不同错误模式并验证Evaluator的分类与定位能力，另构造16例受控错误验证集。

受控验证集错误覆盖

受控错误验证集包含16个错误样本，覆盖8种预定义错误类型：

错误类型	含义	案例数
concept_or_theorem_error	使用了错误的概念、公式或定理	4
condition_omission	遗漏题目给定或推导所需的条件	3
calculation_error	运算、代数变换或数值计算错误	2
case_omission	未覆盖必要的分类讨论或分支	2
invalid_derivation	已有前提无法推出后续结论	2
problem_misinterpretation	错误理解题意、目标或已知信息	1
insufficient_justification	关键结论缺少充分依据	1
answer_extraction_or_format_error	最终答案提取或输出格式不符合要求	1
合计	—	16

该分布是实验设计中的人为覆盖分布，用于Evaluator有效性验证，不代表Solver在常规模型解答中产生各类错误的频率。受控错误验证集不与常规解答验证集混合计算总体错误率。

5. 结果总结

- 当前45道问题对照中，high和low的最终答案准确率均为45/45；low的total tokens减少63.5%，reasoning tokens减少71.3%。

- 常规解答验证集的人工过程正确率为44/45，其中1例答案正确但过程错误，说明过程评估具有独立价值。
- 当前样本没有显示明确的答案准确率下降区间，也不足以确定稳定的难度临界点。
- 由于常规解答验证集仅出现1例过程错误，错误类型分析采用16例受控错误验证集覆盖8类预定义错误；该分布仅表示实验覆盖范围，不代表Solver在常规模型解答中的错误频率。